RAG Pipeline 설계 및 구축 Report

주제: 저작권 판례 데이터 기반 Improved RAG 구축

비교 기준: 실습_NaiveRAG.ipynb (Baseline) vs Improved_RAG_Copyright_CaseLaw.ipynb

1. 과제 목표

본 과제의 목적은 **실습_NaiveRAG** 의 Basic RAG Process 를 기준으로, 동일한 판례 데이터셋에 대해 RAG 의 성능을 높이는 기법을 적용하여 응답 품질을 개선하는 것이다. Baseline RAG 는 단순 Dense Retrieval 기반 구조이며, 검색된 상위 context 를 그대로 LLM 에 전달하여 답변을 생성한다. 그러나 이 방식은 검색 정확도와 문맥 품질이 제한되어 있어 환각(hallucination)이나 부정확한 답변이 발생할 수 있다.

따라서 본 구현에서는 다음과 같은 Advanced RAG 기법을 적용하여 Baseline 대비 성능 향상을 목표로 하였다.

- Chunking Optimization
- Hybrid Retrieval
- Cross-Encoder Reranker

본 구현에서는 **GroundTruth QA 를 KB 에 넣지 않고 평가 전용으로만 사용**하여, 정답 누수(Data Leakage) 없이 공정한 성능 비교가 가능하도록 설계하였다.

2. 데이터 및 실험 원칙

- Knowledge Base: Copyright_case_law_Supreme.xlsx (판례 423 건)
- Evaluation set: Copyright_QA_GroundTrue.xlsx (질문-정답 31 건)
- GroundTruth QA 를 Knowledge Base 에 포함하지 않은 이유는 다음과 같다.

  정답 문장이 검색 후보에 직접 포함되면 factual_correctness 지표가 인위적으로 상승하여 RAG 성능이 왜곡될 수 있기 때문이다.

• 따라서 이번 과제는 "판례만으로 검색하고, QA 는 평가만 수행하는 구조"로 설계하는 것이 가장 타당하다.

3. 적용한 개선 기법

본 구현에서는 다음 세 가지 개선 기법을 적용하였다.

1. Chunking Optimization

법률 문서의 구조를 고려하여 문맥 단절을 줄이기 위해 chunking 전략을 개선하였다.

- chunk_size: 500 → **1200**
- overlap: 50 → **150**
- 법률 문서 구조 기반 separator 적용

이를 통해 판결 이유나 법적 판단 단락이 하나의 청크에 포함되도록 하여 검색 시 의미 단절을 최소화하였다.

---

2. Hybrid Retrieval

Baseline 은 Dense Retrieval 만 사용하지만, 법률 질의는 정확한 키워드와 의미 검색이 모두 중요하다.
따라서 다음 두 검색 방식을 결합하였다.

- Dense Retrieval (Vector similarity)
- BM25 Keyword Retrieval

Hybrid Retrieval 을 통해 조문 번호나 법률 용어와 같은 정확한 키워드 매칭과 의미 기반 검색을 동시에 수행할 수 있다.

---

3. Cross-Encoder Reranker

Dense Retrieval 은 질의와 문서를 독립적으로 인코딩하기 때문에 세밀한 문맥 관계를 충분히 반영하지 못할 수 있다.

따라서 1 차 검색 후보 문서를 Cross-Encoder 기반 Reranker 로 재평가하여 실제 관련성이 높은 문서를 상위 context 로 재정렬하였다.

이 과정은 최종 LLM 에 전달되는 context 품질을 크게 향상시킨다.

4. Baseline 대비 변경점

구분	Baseline (실습_NaiveRAG)	Improved RAG
Chunking	500 / overlap 50	1200 / overlap 150 + 법률 separator
Retrieval	Dense only, top-3	Dense + BM25 Hybrid
Post-Retrieval	없음	Cross-Encoder Reranker top-5
KB 구성	판례 데이터	판례 데이터
평가 데이터	QA GroundTruth	QA GroundTruth

5. 실험 결과

아래 표는 노트북 실행 후 값을 채워 제출하면 된다. Improved RAG 노트북은 summary CSV 를 자동 저장하도록 구성했다.

모델	Context Recall	Faithfulness	Factual Correctness
Baseline (실습_NaiveRAG)	0.8000	0.8504	0.4025
Improved RAG	0.8288	0.7077	0.4081

6. 결과 해석

Improved RAG 는 Hybrid Retrieval 과 Reranker 를 적용함으로써 검색된 문서의 다양성과 관련성이 향상되었으며 Context Recall 지표가 Baseline 대비 상승하였다.

반면 Faithfulness 지표는 다소 감소하였는데, 이는 Hybrid Retrieval 을 통해 더 다양한 문서가 context 로 제공되면서 LLM 이 보다 확장된 설명을 생성했기 때문으로 해석할 수 있다.

Factual Correctness 는 Baseline 대비 소폭 상승하여 GroundTruth 답변의 핵심 정보를 재현하는 능력이 개선된 것을 확인할 수 있었다.

즉, Improved RAG 는 Retrieval 성능을 향상시키는 대신 context 다양성이 증가하면서 일부 Faithfulness 지표가 감소하는 경향을 보였으며, 이는 RAG 시스템 설계에서 검색 범위와 답변 근거성 사이의 trade-off 가 존재함을 보여준다.

Hybrid Retrieval 은 Dense Retrieval 의 의미 기반 검색과 BM25 의 키워드 기반 검색을 결합하여 법률 질의에 보다 적합한 검색 결과를 제공한다.

또한 Cross-Encoder Reranker 는 1 차 검색 결과를 재평가하여 실제 질문과 가장 관련성이 높은 문서를 상위 context 로 선택하도록 하였다.

이러한 구조적 개선은 LLM 이 보다 정확한 근거 문서를 기반으로 답변을 생성하도록 유도하며, 결과적으로 RAG 시스템의 신뢰성을 향상시킨다.

따라서 본 실험에서는 Hybrid Retrieval 과 Cross-Encoder Reranker 를 적용한 Improved RAG 구조가 Baseline Naive RAG 대비 더 안정적인 검색 성능과 근거 기반 응답 생성을 제공하는 것을 확인할 수 있었다.

7. Lessons Learned

이번 프로젝트를 통해 다음과 같은 인사이트를 얻을 수 있었다.

1. 데이터셋 설계의 중요성

GroundTruth QA 를 Knowledge Base 에 포함하면 성능이 쉽게 높아질 수 있지만 이는 평가 누수 문제를 발생시킨다. 실제 RAG 시스템 평가에서는 Knowledge Base 와 Evaluation Dataset 을 명확히 분리하는 것이 중요하다.

2. Chunking 전략의 영향

법률 문서는 문맥 의존성이 매우 높기 때문에 적절한 chunk_size 와 overlap 설정이 검색 품질에 큰 영향을 미친다.

3. Hybrid Retrieval 의 효과

법률 질의는 정확한 조문 번호나 키워드 검색이 중요하기 때문에 Dense Retrieval 단독보다 Hybrid Retrieval 이 더 안정적인 성능을 보였다.

4. Reranker 의 역할

Dense 검색 상위 결과를 그대로 사용하는 것보다 Cross-Encoder 기반 Reranker 를 통해 문서를 재정렬하면 최종 context 품질이 개선될 수 있다.